

## Módulo 11

### OpenMP 2 : GEMM

#### **GEMM**

Copie o ficheiro `/share/acomp/GEMM-P11.zip` para a sua directoria e faça o unzip; será criada a directoria de trabalho para este módulo, designada de `P11`. Visualize a função `gemml0()`, cujo código se repete a seguir:

```
void gemml0 (float *__restrict__ a, float *__restrict__ b, float *__restrict__ c,
int n) {
    #pragma omp parallel
    {
        int i, j, k;
        float aik;

        MYPAPI_thread_start(omp_get_thread_num());
        #pragma omp for
        for (i = 0; i < n; ++i) {
            for(k = 0; k < n; k++ ) {
                aik = a[i*n+k];
                for (j = 0; j < n; ++j) {
                    /* c[i][j] += a[i][k]*b[k][j] */
                    c[i*n+j] += aik * b[k*n+j];
                }
            }
        }
        MYPAPI_thread_stop(omp_get_thread_num());
    }
}
```

Note que o código é equivalente ao de `gemm3()`, com as seguintes diferenças:

- é criado um bloco paralelo – a partir deste ponto, e até ao fim deste bloco, o código respectivo é executado em paralelo por um determinado número de *threads*;
- há um conjunto de variáveis declaradas dentro do contexto do bloco paralelo, garantindo assim que estas são **locais** a cada uma das *threads*;
- As funções `MYPAPI_thread_start()` e `MYPAPI_thread_stop()` são invocadas antes e depois da execução dos ciclos *for*, mas dentro do bloco paralelo, para instrumentar cada uma das *threads*, lendo os respectivos contadores de eventos;
- a directiva `#pragma omp for` é colocada antes do ciclo *for* mais externo, para que o seu espaço de iteração seja distribuído pelas várias *threads*.

**Exercício 1** – Construa o executável e execute `gemm3()`:

```
sbatch gemm.sh 1024 3
```

Preencha a respectiva linha na Tabela 1.

No próximo exercício iremos executar `gemm10()`. Note que:

- para executar versões do `gemm` com ID igual a superior a 10 (isto é, que usam OpenMP) é necessário indicar o número de *threads* a utilizar. Para usar 8 *threads* escreva:

```
sbatch gemm.sh 1024 10 8
```

A omissão do 3º parâmetro resulta na criação de apenas 1 *thread*.

- o tempo de execução de um programa paralelo, conforme percebido pelo utilizador, corresponde ao tempo do último processador a terminar. Admitindo que a frequência do *clock* do processador é fixa, então tal corresponde ao processador que usa mais *clock cycles* para executar a sua *thread*. O CPI percebido corresponde portanto ao número de ciclos que decorrem desde que a função inicia até que termina, dividido pelo número total de instruções executado por **todas as threads**. Esta métrica é reportada pelo programa para versões do `gemm()` maiores ou iguais a 10.

**Exercício 2** – Execute `gemm10()` usando 1, 2, 4, 8, 16 e 32 *threads* e preencha as respectivas linhas na Tabela 1. As 2 colunas da direita (SpeedUp e Eficiência) serão preenchidas no próximo exercício.

**NOTA:** A máquina usada neste exercício tem 16 *cores* físicos. Cada um deles suporta *Simultaneous Multithreading* (*HyperThreading* na terminologia da Intel), pelo que o Sistema Operativo reporta 32 *cores* lógicos.

O **SpeedUp** exprime o ganho, em tempo de execução, quando são usados  $p$  processadores relativamente a uma versão de referência. Esta versão de referência é, frequentemente, a versão sequencial (1 processador apenas) que usa o mesmo algoritmo que a versão paralela, resultando naquilo que na literatura se designa por *relative speedup*. Esta é a definição que usaremos para medir o ganho, resultando na expressão

$$S_p = \frac{T_1}{T_p}$$

onde  $S_p$  é o *speedup* com  $p$  processadores,  $T_p$  o tempo de execução com  $p$  processadores e  $T_1$  o tempo de execução com 1 processador.

A **Eficiência** indica quão longe o *speedup* obtido está do *speedup* ideal. No caso em que todos os  $p$  processadores são idênticos o *speedup* ideal é igual ao número de processadores. Isto é, se usamos 2 processadores então esperamos um ganho de 2, se usarmos 16 processadores esperamos um ganho de 16 – este resultado é designado por *speedup linear*. A eficiência indica em que percentagem atingimos este objectivo e é dada por:

$$E_p = \frac{S_p}{p} * 100$$

**Exercício 3** – Preencha agora as colunas de SpeedUp e Eficiência da Tabela 1 para `gemm10()` usando como tempo de referência,  $T_1$ , o tempo de `gemm3()`.

Como evolui a eficiência com o aumento do número de processadores? Porquê?

**Exercício 4** – Pretende-se que `gemml1()` combine o *multithreading* com a vectorização. Escreva o código de `gemml1()`, usando auto-vectorização, tendo em consideração que:

- o código é em tudo idêntico ao de `gemml0()`;
- é necessário activar a opção `tree-vectorize`, já incluída no código fornecido;
- é necessário preceder o ciclo a vectorizar (isto é, o ciclo *for* mais aninhado – índice `j`) com a directiva `#pragma omp simd` (na ausência desta directiva o compilador não vectorizará o código deste ciclo enquanto usa simultaneamente o OpenMP).

Construa o executável. Preencha a linha correspondente a `gemm6()` na Tabela 1. Esta é a versão sequencial equivalente a `gemml1()`. Preencha as linhas correspondentes a `gemml1()` na mesma tabela. Para o cálculo do *speedup* e eficiência use como tempo de referência,  $T_1$ , o tempo de `gemm6()`.

**RESOLUÇÃO:**

```
#pragma GCC optimize("tree-vectorize")
void gemml1 (float *__restrict__ a, float *__restrict__ b, float *__restrict__ c, int n)
{
    #pragma omp parallel
    {
        int i, j, k;
        float aik;

        MYPAPI_thread_start(omp_get_thread_num());
        #pragma omp for
        for (i = 0; i < n; ++i) {
            for(k = 0; k < n; k++ ) {
                aik = a[i*n+k];
                #pragma omp simd
                for (j = 0; j < n; j++) {
                    /* c[i][j] += a[i][k]*b[k][j] */
                    c[i*n+j] += aik * b[k*n+j];
                }
            }
        }
        MYPAPI_thread_stop(omp_get_thread_num());
    }
}
#pragma GCC reset_options
```

**Exercício 5** – Desenvolva o código de `gemml2()`, baseado em `gemm8()` e `gemml0()`, usando *compiler intrinsics* para vectorizar.

Construa o executável. Preencha a linha correspondente a `gemm8()` na Tabela 1. Esta é a versão sequencial equivalente a `gemml2()`. Preencha as linhas correspondentes a `gemml2()` na mesma tabela. Para o cálculo do *speedup* e eficiência use como tempo de referência,  $T_1$ , o tempo de `gemm8()`.

**RESOLUÇÃO:**

```

void gemm12 (float *__restrict__ a, float *__restrict__ b, float *__restrict__ c, int n)
{
    #pragma omp parallel
    {
        int i, j, k;
        __m256 aik, bkj, cij, prod;

        MYPAPI_thread_start(omp_get_thread_num());
        #pragma omp for
        for (i = 0; i < n; ++i) {

            for(k = 0; k < n; k++ ) {
                // set all 8 elements of aik with a[i,k]
                aik = _mm256_broadcast_ss (&a[i*n+k]);
                // add 8 to j since 8 SPFP are processed per iteration
                for (j = 0; j < n; j+=8) {
                    // c[i][j] += a[i][k]*b[k][j]
                    bkj = _mm256_load_ps (&b[k*n+j]);
                    cij = _mm256_load_ps (&c[i*n+j]);
                    prod = _mm256_mul_ps (aik, bkj);
                    cij = _mm256_add_ps (cij, prod);
                    _mm256_store_ps (&c[i*n+j], cij);
                }
            }
        }
        MYPAPI_thread_stop(omp_get_thread_num());
    }
}

```

**Exercício 6** – Iniciamos o semestre com a versão mais ineficiente da multiplicação de matrizes, nomeadamente, `gemm1()`. Neste caminho quantas vezes mais rápida ficou a nossa função? Preencha o quadro abaixo, usando o melhor resultado que obteve (terá sido com `gemm11()` ou `gemm12()`).

Versão	Threads	T (ms)	Ganho
<code>gemm1()</code>	1		-----
<code>gemm11()</code>			

**Exercício 7** – De facto, a primeira versão de `gemm1()` foi compilada sem optimizações (`-O0`). Use a directiva `#pragma GCC optimize("O0")` para gerar essa primeira versão e calcule o ganho total que obtivemos.

<code>gemm1 (-O0)</code> T (ms)	<code>gemm11/12</code> T (ms)	Ganho

Tabela 1 - Resultados GEMM (n=1024)

Ver.	Obs	#threads	T(ms)	#I(M)	CPI	SpeedUp	Eficiência
gemm3 ()	Versão base	1				---	---
gemm10 ()	Versão base + OpenMP	1				1,0	100%
		2					
		4					
		8					
		16					
		32					
gemm6 ()	Compiler vectorization	1				---	---
gemm11 ()	Compiler vectorization + OpenMP	1				1,0	100%
		2					
		4					
		8					
		16					
		32					
gemm8 ()	Intrinsics vectorization	1				---	---
gemm12 ()	Intrinsics vectorization + OpenMP	1				1	100%
		2					
		4					
		8					
		16					
		32					